

# Perfect Match NBA players: Sistema de Recomendação Autoexplicativo de jogadores de NBA

Diogo Fontes  
Departamento de Engenharia Informática  
IACH, MECD  
dmf@student.uc.pt

José Silva  
Departamento de Engenharia Informática  
IACH, MECD  
uc2020237724@student.uc.pt

Universidade de Coimbra

## Abstract

Na atualidade, a vasta quantidade de dados disponíveis requer a organização da informação que é entregue ao público final. Os sistemas de recomendação desempenham um papel crucial nesse contexto, uma vez que apresentam ao utilizador apenas os dados que mais se adequam aos seus interesses, seja por configuração manual ou perfil previamente definido. No entanto, para que tais sistemas de recomendação sejam genuinamente aceites pelos seres humanos, é imprescindível que justifiquem as recomendações que oferecem. Somente dessa forma um utilizador se sentirá plenamente esclarecido acerca das opções geradas pelo sistema. É sob essa perspectiva que optamos por desenvolver um sistema de recomendação autoexplicativo, focado na identificação de jogadores que atuam na NBA, a prestigiada liga de basquetebol norte-americana. Este sistema visa simplificar a vida das entidades ligadas ao basquetebol, proporcionando economia de tempo e de recursos humanos, enquanto fornece uma análise minuciosa dos benefícios e desvantagens associados à contratação de jogadores específicos. Palavras-chave: basquetebol, sistema de recomendação, inteligência artificial, jogadores, explicabilidade.

## 1 Introdução

Este relatório introduz um projeto inovador na esfera do basquetebol, especialmente focado na NBA, que visa revolucionar a forma como as equipas contratam jogadores. O sistema de recomendação proposto alia a

inteligência artificial e a análise de dados para identificar talentos que melhor se ajustam às necessidades específicas de uma equipa, reduzindo significativamente os riscos e custos associados às transferências.

A essência deste sistema reside na sua capacidade de não apenas sugerir jogadores com características semelhantes às desejadas, mas também de explicar de forma clara as razões por trás de cada recomendação. Este aspecto de transparência e explicabilidade distingue-o de outros sistemas existentes, garantindo que os clubes compreendam plenamente as implicações de cada sugestão.

Um exemplo prático da aplicação deste sistema pode ser observado na situação dos Knicks e a procura de um jogador com atributos semelhantes aos de Giannis Antetokounmpo dos Bucks. Aqui, o sistema não se limitaria a listar jogadores com estatísticas parecidas; ele também forneceria uma análise aprofundada, justificando por que cada jogador é uma boa opção.

Para atingir um nível elevado de precisão e clareza nas recomendações, implementamos uma abordagem bifacetada no nosso sistema. A primeira parte baseia-se na utilização da distância de cosseno, uma métrica que avalia a similaridade entre jogadores com base na orientação dos seus vetores de atributos. Este método é particularmente eficaz para identificar jogadores cujas habilidades e estilos de jogo são semelhantes, independentemente das suas estatísticas gerais.

A segunda parte do sistema emprega técnicas de clustering. Aqui, os jogadores são agrupados com base na semelhança dos seus atributos e desempenhos, permitindo uma análise mais granular. Esta abordagem facilita a identificação de grupos e subgrupos de jogadores que podem não ser imediatamente óbvios através de métodos tradicionais, oferecendo uma perspectiva mais holística e detalhada.

Após a implementação destes dois métodos, procedemos a uma comparação detalhada, utilizando

métricas. Esta comparação não se limita apenas a avaliar qual método é mais eficaz na identificação de jogadores semelhantes, mas também examina a capacidade de cada método em fornecer recomendações compreensíveis.

A combinação desses dois sistemas - distância de cosseno e clustering - permite uma avaliação robusta e multifacetada dos jogadores, abrindo caminho para recomendações mais precisas e bem fundamentadas. Este processo de comparação e avaliação constante assegura que o sistema não só mantenha a sua relevância, mas também continue a evoluir e a aprimorar-se, alinhando-se com as dinâmicas em constante mudança da NBA e das suas equipas.

As expectativas para este projeto são altas. Espera-se que ele ofereça uma maior acertividade nas contratações, reduzindo os riscos financeiros e melhorando a composição dos plantéis. Além disso, a transparência e a explicabilidade do sistema prometem estabelecer um novo padrão na maneira como as contratações são realizadas na NBA, tornando o processo mais eficiente e informado.

Este relatório detalhará os aspectos técnicos do sistema, as metodologias adotadas, os resultados esperados e as contribuições potenciais para o mundo do basquetebol profissional.

## 2 Trabalho relacionado

O desenvolvimento de sistemas de recomendação de jogadores no desporto tem evoluído significativamente. Desde os primeiros métodos baseados em análises estatísticas simples, até as abordagens atuais que utilizam Machine Learning e inteligência artificial, a trajetória destes sistemas reflete os avanços tecnológicos e metodológicos na área.

Na NBA, vários estudos exploram diferentes métodos para avaliar jogadores. Estes variam desde análises baseadas em estatísticas de jogo até avaliações de desempenho físico e técnico. Estes sistemas tentam identificar os jogadores que melhor se adequam às estratégias e às necessidades da equipa.

Vários estudos utilizaram métricas de similaridade, como a distância de cosseno e a Euclidiana, para comparar jogadores. Estas métricas permitem avaliar a semelhança entre jogadores em diversos aspectos, destacando-se em contextos onde a comparação direta das habilidades é essencial.

As técnicas de clustering são aplicadas para agrupar jogadores com base em habilidades ou estilos de jogo similares. Estes estudos demonstram como o clustering pode ser usado para identificar padrões e categorias dentro de dados de desporto.

A importância da explicabilidade e da transparência em sistemas de IA é crucial, especialmente quando

as decisões afetam aspectos financeiros e estratégicos, como nas contratações na NBA. A clareza em como os sistemas chegam a suas conclusões ajuda a reforçar a confiança nas recomendações fornecidas.

Ao comparar o nosso sistema com trabalhos existentes, podemos destacar inovações como a combinação de distância de cosseno com técnicas de clustering e uma ênfase na explicabilidade. Estas características tornam o nosso projeto diferente dos demais, oferecendo abordagens mais refinadas para as recomendações.

## 3 Dados e Abordagem

No cerne do nosso sistema de recomendação de jogadores da NBA está a integração de três datasets. Essa combinação foi estrategicamente escolhida para criar o conjunto de dados mais completo e multifacetado possível, incluindo todos os atributos relevantes para a avaliação e contratação de jogadores. Os datasets incluem:

- **Estatísticas de Desempenho da NBA:** Este dataset fornece dados detalhados sobre o desempenho dos jogadores em jogos, incluindo pontos, assistências, ressaltos, percentagem de acerto, entre outros. Este dataset oferece uma visão quantitativa do impacto de cada jogador em campo.
- **Dados Físicos e Médicos dos Jogadores:** Este dataset abrange informações físicas como altura e peso. Estes dados são cruciais para avaliar a aptidão física.
- **Salário:** Embora o salário não seja o atributo mais importante na avaliação das habilidades e do desempenho de um jogador, ele desempenha um papel significativo no processo de contratação por parte das equipas. A consideração do salário é essencial para equilibrar o orçamento da equipa e assegurar que as contratações se alinhem com as restrições financeiras e estratégias de gestão de recursos.

Após a integração dos três datasets, iniciamos o processo de normalização dos dados para garantir a consistência e a confiabilidade das informações. Enfrentamos o desafio de lidar com dados incompletos em algumas variáveis chave, como salário, altura e peso dos jogadores. Para abordar estas lacunas, adotamos estratégias específicas:

- **Salário:** Nos casos em que as informações salariais estavam ausentes, optamos por atribuir o salário mínimo estabelecido para um jogador da NBA. Esta decisão permite manter a integridade dos

dados financeiros, garantindo uma base de comparação justa e realista em termos de custos de contratação.

- **Altura:** Para jogadores sem dados sobre a sua altura, utilizamos a média da altura específica para a posição de cada jogador. Esta abordagem assegura que as estimativas de altura se alinhem com as normas físicas típicas para cada posição, proporcionando uma base de comparação mais precisa.
- **Peso:** De forma semelhante à altura, nos casos em que o peso não estava disponível, atribuímos o peso médio correspondente à posição do jogador. Isso reflete uma estimativa realista do perfil físico esperado para a posição, mantendo a consistência dos dados.

Antes de darmos início ao desenvolvimento do sistema de recomendação, empreendemos uma análise detalhada das características do nosso dataset final. Esta etapa preliminar foi crucial para compreender a profundidade e a abrangência dos dados disponíveis, assegurando que o sistema fosse construído sobre uma base sólida e bem informada.

Para validar a eficácia do nosso sistema, fizemos alguns testes e simulações. Comparamos as recomendações do nosso sistema com o feedback de entendedores de basquetebol. Estes testes ajudaram a perceber se as nossas recomendações eram válidas ou não.




Figure 1: Principais jogadores por posição

Este gráfico de barras destaca o desempenho dos principais jogadores da NBA por posição, com base em três estatísticas-chave: pontos (PTS), assistências (AST) e rebotes (TRB). Cada barra representa um jogador diferente e está colorida de acordo com a sua posição: Center (C), Power Forward (PF), Point Guard (PG), Small Forward (SF) e Shooting Guard (SG). As estatísticas médias de cada posição são indicadas na legenda. Este gráfico pode ser utilizado para ilustrar a importância de diferentes atributos de desempenho na avaliação e recomendação de jogadores. As diferenças nas médias por posição também podem ajudar a destacar as especializações de cada jogador e como isso pode ser relevante na formulação de estratégias para equipes e no desenvolvimento de algoritmos

de recomendação mais eficazes. Para além disto, estes poderão ser jogadores de referência para testes no nosso sistema de recomendação, pois são melhores jogadores por posição no quesito pontuar por jogo.




Figure 2: Número de jogadores por equipa

Este gráfico de barras apresenta a quantidade de jogadores por franquia na NBA. Observamos uma distribuição relativamente uniforme do número de jogadores entre as diferentes franquias, com ligeiras variações. Por exemplo, a franquia representada por "UTA" parece ter o maior número de jogadores, enquanto "PHO" tem o menor, dentro do conjunto de dados apresentado. Este gráfico é útil porque podemos perceber quais são as franquias que têm uma menor profundidade de escolha em termos de jogadores (por exemplo PHO). Com este sistema de recomendação podemos ajudar estas a procurarem jogadores semelhantes de outras franquias para tornar um plantel mais equilibrado.




Figure 3: Percentagem de jogadores por posição

Este gráfico em forma de pizza mostra a distribuição percentual de jogadores por posição num dataset da NBA. Podemos ver que as posições estão bastante equilibradas, com uma pequena predominância de jogadores na posição de Shooting Guard (SG), que representam 23,7% do total. A posição com a menor percentagem é Point Guard (PG), com 17,3%. As posições de Power Forward (PF) e Small Forward (SF) estão muito próximas em termos de representação, com 19,3% e 19,7% respectivamente, enquanto os Centers (C) representam 20,0%. No contexto de um sistema de recomendação, esta análise é crucial para entender a distribuição de jogadores disponíveis e pode influenciar a forma como o sistema recomendará posições a diferentes equipes. Por exemplo, se

uma equipa precisa de um Point Guard (PG), o sistema pode precisar considerar que existe uma menor proporção deles no conjunto de dados, o que poderia influenciar a competição e a seleção de jogadores recomendados.

## 4 Experimentation

### 4.1 Setup

Após o tratamento de dados descrito na secção anterior, encontrávamo-nos na posição ideal para avançar com o desenvolvimento do nosso sistema de recomendação. Optámos por calcular as semelhanças entre jogadores através da distância de cosseno. Esta escolha deve-se à eficácia desta métrica na comparação de dois vetores em espaços de alta dimensionalidade, um aspecto onde a distância euclidiana pode não ser tão eficiente. Por conseguinte, concentrámo-nos exclusivamente nos valores numéricos - as avaliações atribuídas a diversos atributos dos jogadores - pois são estes os únicos dados compatíveis com esta técnica.

Com o foco nos dados numéricos, recorremos à Análise de Componentes Principais (PCA) para otimizar o desempenho do nosso sistema de recomendação, visando uma redução significativa no tempo de processamento. A PCA é uma técnica que permite reduzir a dimensionalidade dos dados, eliminando atributos fortemente correlacionados sem perda significativa de informação.

Ao analisar o gráfico de cotovelo apresentado a seguir, concluímos que 32 características são suficientes para distinguir eficazmente os jogadores uns dos outros, preservando a integridade das informações relevantes. Este balanceamento cuidadoso entre a redução de dimensionalidade e a manutenção de informações chave é crucial para a eficácia do nosso sistema de recomendação.

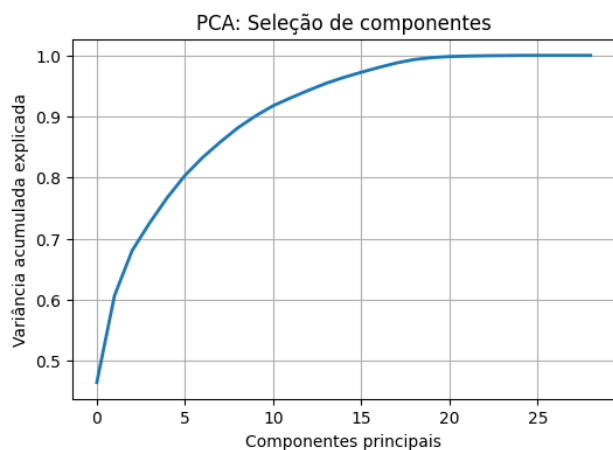


Figure 4: Seleção de Componentes

Com a aplicação da Análise de Componentes Principais (PCA), conseguimos reduzir eficazmente a dimensionalidade do nosso problema, eliminando redundâncias e preparando os dados para uma comparação mais eficiente. Neste contexto, procedemos à comparação de cada jogador do nosso dataset com todos os outros, gerando assim um conjunto abrangente de métricas de semelhança entre todos os atletas. Esta abordagem permite que qualquer jogador possa ser sugerido como recomendação com base nas suas qualidades intrínsecas, independentemente da sua posição original. Embora possa parecer improvável, isto significa que, por exemplo, um SG poderia ser recomendado na procura de um PG, caso as suas habilidades e atributos se alinhem.

Com todas as métricas de semelhança calculadas, o sistema está pronto para ser utilizado. O utilizador inicia o processo introduzindo o nome do jogador que deseja usar como referência para as recomendações. Para garantir precisão e evitar ambiguidades, o nosso sistema utiliza um método de indexação por nome. A fim de assegurar que a busca do utilizador corresponda exatamente aos dados que temos na nossa base, implementámos o sistema da seguinte maneira: primeiramente, o utilizador escolhe a equipa e depois o jogador desejado.

Uma vez introduzido o nome do jogador, o sistema apresenta uma lista de cinco jogadores cujas características mais se assemelham ao selecionado, ordenados por grau de semelhança. Esta abordagem não só facilita a escolha do utilizador, mas também oferece uma visão ampla das opções disponíveis, maximizando as possibilidades de encontrar o jogador ideal para qualquer situação específica.

Como mencionado anteriormente, implementamos técnicas de clustering no nosso sistema para validar e complementar o método baseado na distância de cosseno. Esta abordagem integrada permitiu-nos uma comparação mais robusta e uma validação cruzada da eficácia do nosso sistema de recomendação.

Inicialmente, carregámos os dados do nosso dataset que contém informações abrangentes sobre os jogadores. Focámo-nos em colunas numéricas, pois são essenciais para a aplicação de técnicas de Machine Learning. Para lidar com os valores ausentes nessas colunas, substituímo-los pela média dos valores existentes, garantindo assim a integridade dos nossos dados. Uma etapa única no nosso processo foi a filtragem dos jogadores com base na sua posição. Isto foi conseguido através de um mapeamento que nos permitiu selecionar jogadores que ocupam posições semelhantes ou complementares à do jogador em foco, possibilitando recomendações mais precisas e contextualizadas. Para o tratamento dos dados, seleccionámos várias características numéricas relevantes, como es-

tatísticas de jogo e performance. Estes dados foram normalizados usando o StandardScaler para assegurar que todas as variáveis tivessem igual peso na análise subsequente. Em seguida, aplicamos a técnica de PCA (Análise de Componentes Principais) para reduzir a dimensionalidade dos dados, transformando-os em três componentes principais. Esta redução é crucial para simplificar os dados mantendo as informações mais relevantes. Com os componentes principais definidos, criamos um DataFrame que inclui estes componentes juntamente com os nomes dos jogadores. Implementamos um sistema de coloração para destacar jogadores específicos: um jogador de referência em vermelho e um conjunto de jogadores de destaque em verde. Esta visualização foi materializada num gráfico 3D interativo, criado com Plotly Express, que nos permite observar as relações espaciais entre os jogadores com base nos seus componentes principais.

O gráfico resultante fornece uma representação visual intuitiva das semelhanças entre jogadores, com base nas suas habilidades e desempenhos, permitindo identificar rapidamente os jogadores com características mais próximas às do jogador de referência. Esta abordagem não só oferece uma visão clara e interativa das relações entre os jogadores, mas também é uma ferramenta inestimável para facilitar decisões de recrutamento e estratégia de equipe.

3D PCA de Jogadores da NBA



Figure 5: Clustering-Jogador selecionado: Stephen Curry

## 4.2 Avaliação Quantitativa

Para avaliar a eficácia destas abordagens, implementamos uma rigorosa estratégia de avaliação, centrando-nos na métrica F1 Score, que combina precisão e recall em um único indicador. Esta métrica é particularmente relevante no contexto dos nossos objetivos, pois permite um equilíbrio entre a identificação de todos os jogadores potencialmente relevantes (recall) e a garantia de que as recomendações feitas são de fato pertinentes (precisão).

Verdadeiros Positivos (VP) são casos onde o modelo previu corretamente a classe positiva. Falsos Positivos (FP) são casos onde o modelo previu incorretamente a classe positiva. Falsos Negativos (FN) são casos onde o modelo falhou em identificar a classe positiva.

$$Precisão = \frac{VerdadeirosPositivos}{VerdadeirosPositivos + FalsosPositivos}$$

$$Recall = \frac{VerdadeirosPositivos}{VerdadeirosPositivos + FalsosNegativos}$$

$$F1Score = 2 * \frac{Precisão * Recall}{Precisão + Recall}$$

Exemplo para Stephen Curry:

Distância de cosseno:

$$Precisão = \frac{83}{83 + 12} = 0,87$$

$$Recall = \frac{83}{83 + 0} = 1$$

$$F1Score = 2 * \frac{0,87 * 1}{0,87 + 1} = 0,93$$

Clustering:

$$Precisão = \frac{221}{221 + 138} = 0,62$$

$$Recall = \frac{221}{221 + 0} = 1$$

$$F1Score = 2 * \frac{0,62 * 1}{0,62 + 1} = 0,77$$

Um F1 Score de 0,93 para a distância de cosseno é muito alto, o que sugere que este método é muito eficaz tanto em precisão quanto em recall. Isso significa que ele é capaz de identificar uma grande proporção de jogadores relevantes (alto recall) e, ao mesmo tempo, mantém um alto nível de acerto nas suas recomendações (alta precisão).

Por outro lado, um F1 Score de 0,77 para o clustering ainda é bom, mas indica um desempenho moderado em comparação com a distância de cosseno. Isso pode ser devido a várias razões, como a escolha dos parâmetros do algoritmo de clustering, a natureza dos dados, ou a maneira como os clusters foram utilizados no processo de recomendação.

Estes resultados podem indicar que, para este conjunto de dados e critérios usados neste sistema, a distância de cosseno é mais adequada para identificar jogadores semelhantes. No entanto, é importante considerar que diferentes métodos podem ter os seus pontos fortes em diferentes contextos. O clustering, por

exemplo, pode revelar insights únicos sobre agrupamentos e padrões que não são imediatamente aparentes através da distância de cosseno.

A seguir apresentamos os 5 jogadores mais parecidos com o Stephen Curry. Para além de observarmos o gráfico PCA para comprovar o nosso sistema de recomendação, decidimos observar o overall dos jogadores no jogo nba2k23. Este jogo atribui um valor geral que representa de uma forma global o jogador. Pela análise destes, observamos que todos os jogadores tem um overall parecido.

Table 1: Jogadores mais parecidos com Stephen Curry

Jogador	Posição	Overall 2k23
Stephen Curry	Point Guard	96
Damian Lillard	Point Guard	91
Kyrie Irving	Shooting Guard	90
Luka Dončić	Point Guard	97
Devin Booker	Shooting Guard	91
Donovan Mitchell	Shooting Guard	90

Exemplo para Anthony Davis:

$$Precisão = \frac{98}{98 + 6} = 0,94$$

$$Recall = \frac{98}{98 + 0} = 1$$

$$F1Score = 2 * \frac{0,94 * 1}{0,94 + 1} = 0,97$$

Clustering:

$$Precisão = \frac{108}{108 + 10} = 0,92$$

$$Recall = \frac{108}{108 + 0} = 1$$

$$F1Score = 2 * \frac{0,92 * 1}{0,92 + 1} = 0,96$$

Neste caso como todos os jogadores semelhantes são da mesma posição (Center), ambos os modelos apresentam F1 score igual. O que indica que para posições específicas ambos os modelos são eficazes.

A seguir apresentamos os 5 jogadores mais parecidos com o Stephen Curry. Para além de observarmos o gráfico PCA para comprovar o nosso sistema de recomendação, decidimos observar o overall dos jogadores no jogo nba2k23. Este jogo atribui um valor geral que representa de uma forma global o jogador. Pela análise destes, observamos que todos os jogadores apresentam um overall semelhante, apesar de não ser tão parecidos como no caso anterior.

Table 2: Jogadores mais parecidos com Anthony Davis

Jogador	Posição	Overall 2k23
Anthony Davis	Center	93
Joel Embiid	Center	96
Nikola Jokić	Center	97
Kristaps Porziņģis	Center	86
Bam Adebayo	Center	87
Deandre Ayton	Center	84

## 5 Conclusão

Este projeto representa um marco significativo na integração de sistemas inteligentes no domínio do desporto, particularmente na NBA. Conseguimos desenvolver um sistema de recomendação robusto, que utiliza técnicas avançadas como a distância de cosseno e clustering para oferecer recomendações precisas e personalizadas de jogadores. Uma das principais dificuldades enfrentadas foi a necessidade de tratar e normalizar grandes conjuntos de dados, garantindo que os algoritmos pudessem operar com a máxima eficiência e precisão.

Este sistema é um exemplo claro de como a co-operação entre humanos e inteligência artificial pode gerar resultados superiores. A integração do conhecimento humano, em termos de estratégias de jogo e compreensão das nuances do basquetebol, com a capacidade analítica da IA, permite um processo de tomada de decisões mais informado e eficiente, tanto para treinadores como para diretores de equipas.

A transparência e a explicabilidade foram pilares fundamentais deste projeto. Ao assegurar que as recomendações do sistema são acompanhadas de justificações claras e compreensíveis, reforçamos a confiança dos utilizadores na IA. Além disso, a atenção às questões éticas e de privacidade garantiu que o sistema fosse não só eficaz, mas também justo e responsável.

O sistema de recomendação emprega capacidades cognitivas avançadas, processando e interpretando grandes quantidades de dados para identificar padrões e correlações que não seriam facilmente perceptíveis. Este nível de análise cognitiva é crucial para recomendações precisas e úteis.

O projeto contribui significativamente para o campo dos sistemas de recomendação, demonstrando como algoritmos sofisticados podem ser aplicados para fornecer soluções específicas e altamente relevantes no contexto do desporto. Este sistema pode ser visto como um passo em direção ao desenvolvimento de agentes de assistência pessoal inteligentes no domínio desportivo, capazes de fornecer análises e recomendações personalizadas com base em dados complexos.

Existem várias áreas em que este projeto poderia ser expandido no futuro. Uma direção seria a inte-

gração de análises preditivas para prever o desenvolvimento futuro de jogadores com base em tendências de desempenho. Outra possibilidade seria a interação do sistema com dados em tempo real durante os jogos poderia oferecer insights dinâmicos e em constante atualização.

Este projeto não só representa um avanço tecnológico significativo na análise desportiva, mas também destaca o potencial da IA responsável e colaborativa no apoio à tomada de decisões complexas.

## References

- [1] NBA Scouting: Recommendation Engines with K Nearest Neighbors (KNN). Nathan Carabello URL: <https://nathancarabello.medium.com/nba-scouting-recommendation-engines-with-k-nearest-neighbors-knn-8eb0238a53d9> , Aug 26, 2020
- [2] NBA-Draft-2017-Player-Comparison-Generator. Jonathan Berne URL: <https://github.com/bernej/NBA-Draft-2017-Player-Comparison-Generator> , Aug 17, 2017
- [3] Build a Recommendation Engine With Collaborative Filtering Abhinav Ajitsaria URL: <https://realpython.com/build-recommendation-engine-collaborative-filtering/>
- [4] Recommender System : User based Collaborative filtering Deepa Pandit URL: <https://medium.com/@deepapandithu/recommender-system-user-collaborative-filtering-37613f0c6a9> , Jul 7, 2023
- [5] Dataset URL: [https://github.com/zsilva18/Nba\\_Recsys-main/blob/main/datasets/nba\\_final.csv](https://github.com/zsilva18/Nba_Recsys-main/blob/main/datasets/nba_final.csv)
- [6] Dataset original BRYAN WEATHER CHUNG URL: <https://www.kaggle.com/datasets/bryanchungweather/nba-players-data-2022-2023/> , update on 28 Sep, 2023
- [7] How to Build a Winning Recommendation System, Part 1 Carol McDonald and Gabriel Moreira URL: <https://developer.nvidia.com/blog/how-to-build-a-winning-recommendation-system-part-1/> , Apr 26, 2021
- [8] How to Build a Deep Learning Powered Recommender System, Part 2 Carol McDonald URL: <https://developer.nvidia.com/blog/how-to-build-a-winning-recommendation-system-part-2-deep-learning-for-recommender-systems/> , May 2, 2021
- [9] How to Build a Winning Deep Learning Powered Recommender System-Part 3 Carol McDonald, Chris Deotte, Gabriel Moreira, Jean-Francois Puget, Gilberto Titericz, Ronay AK, Even Oldridge, Jiwei Liu and Benedikt Schifferer URL: <https://developer.nvidia.com/blog/how-to-build-a-winning-deep-learning-powered-recommender-system-part-3/> , May 6, 2021
- [10] Building a Player Recommender Tool Avneesh Singh Saini URL: <https://medium.com/analytics-vidhya/building-a-player-recommender-tool-666b5892336f> , Jun 30, 2021
- [11] Tutorial 3A Hands on Explainable Recommender Systems with Knowledge Graphs Giacomo Balloccu, Ludovico Boratto Cagliari, Gianni Fenu, and Mirko Marras URL: <https://www.youtube.com/watch?v=qPiIvcCOyBg> , Feb 20, 2023
- [12] Tutorial 3B Improving Recommender Systems with Human in the Loop Dmitry Ustalov, PhD, Natalia Fedorova, Nikita Pavlichenko URL: [https://www.youtube.com/watch?v=WfKIfWGuO\\_k](https://www.youtube.com/watch?v=WfKIfWGuO_k) , Feb 20, 2023
- [13] Comprehensive Guide to Ranking Evaluation Metrics Vyacheslav Efimov, Towards Data Science URL: <https://towardsdatascience.com/comprehensive-guide-to-ranking-evaluation-metrics> , Jul 29, 2023
- [14] How Are Overall Ratings Determined in NBA 2K? Adarsh Param URL: <https://sportsmanor.com/nba-how-are-overall-ratings-determined-in-nba-2k/> , Jul 7, 2022
- [15] Nba 2k23 players overall Nba 2k23 URL: <https://nba.2k.com/2k23/pt-BR/ratings/> , 2023,
- [16] Repositório com o trabalho José Silva, Diogo Fontes URL: [https://github.com/zsilva18/Nba\\_Recsys-main/](https://github.com/zsilva18/Nba_Recsys-main/) , Nov 16, 2023